


Descrição do problema

O presente trabalho tem por objetivo o desenvolvimento de um *data mart*, com base nos dados de encomendas de clientes, efetuadas à empresa de comércio eletrónico *PlusOrders*, cujo ramo de atividade é a moda de luxo. A empresa é nacional, mas opera a nível internacional possuindo *sites* em diversos países, a partir dos quais os clientes podem realizar as suas encomendas. O sistema operacional existente centraliza todas as encomendas realizadas nesses diversos *sites*. Na figura seguinte apresenta-se o modelo de dados referente à parte do sistema operacional da empresa que suporta a gestão das encomendas de clientes.



A gestão da empresa pretende que se desenvolva um *data mart* que permita a realização de diversas análises históricas às encomendas efetuadas pelos clientes. No desenvolvimento do *data mart* há alguns aspetos a ter em consideração, relacionados com os dados que se encontram na base de dados do sistema operacional:

- Os valores monetários associados às encomendas encontram-se registados na moeda local em que estas ocorreram.
- O mesmo produto pode ter sido introduzido erradamente em duplicado, estando representado com identificadores (i.e., *ProductID*) diferentes na base de dados. Para além disso, o mesmo produto pode não ter um descritivo rigorosamente igual.
- Os custos de expedição (atributo *ShippingCost*) encontram-se ao nível da encomenda e não ao nível de cada produto que faz parte da encomenda.

- O sistema operacional regista sempre a data em que um registo é inserido numa tabela (atributo *CreateDate*). Igualmente, sempre que ocorre uma alteração a um atributo, a respetiva data em que tal ocorreu também é registada (atributo *LastUpdateDate*).

Requisitos do trabalho

Nos pontos seguintes enumeram-se os requisitos que devem ser respeitados no trabalho a efetuar:

- Desenvolver um processo de análise dimensional, a fim de definir e criar o esquema conceptual para o *data mart*, com base na informação atrás disponibilizada e seguindo a metodologia de *Kimball*. Todas as opções tomadas na criação do modelo dimensional devem ser devidamente justificadas no relatório a produzir. O *data mart* a desenvolver deverá ser concebido de modo que permita a realização de consultas/análises **aos dados das encomendas no nível de granularidade mais elementar**, de modo a possibilitar a maior flexibilidade possível para a realização dessas análises de dados.
- Proceder à extração, integração, transformação, limpeza e carregamento dos dados no *data mart*, por intermédio de um *Integration Services Project do Visual Studio* e dos componentes mais adequados que este disponibiliza para as referidas tarefas. Mais especificamente, pretende-se que:
 - Todo o processo de extração, integração, transformação, limpeza e carregamento dos dados deve ser o mais eficiente possível. Por questões de confidencialidade relacionadas com o negócio, apenas foi disponibilizada para a construção do *data mart* uma amostra dos dados que se encontram no sistema operacional. No entanto, o volume de registos é bastante elevado.
 - Os dados podem estar afetados por problemas de qualidade (por exemplo: valores em falta em atributos supostamente de preenchimento obrigatório; valores que violam o domínio do atributo; valores que constituem violações a restrições de integridade). Para a identificação dos problemas que possam existir sugere-se a realização de um processo de *Data Profiling* prévio sobre os dados.
 - O processo de transformação e limpeza deve filtrar todos os registos que se encontram nessas condições. Assim, qualquer registo afetado por problemas de qualidade, cuja correção não seja possível de ser automatizável, não deve ser carregado no *data mart*, sendo armazenado em tabelas especialmente criadas para o

efeito na *Staging Area*. A correção destes problemas e posterior carregamento desses registos para o *data mart* fica excluída do âmbito deste trabalho.

- A fase de limpeza de dados deve ser efetuada de modo a eliminar todas as redundâncias (registos duplicados iguais ou aproximadamente iguais) que possam existir nos dados, oriundos do sistema operacional.
- O carregamento dos dados no *data mart* (tabelas de dimensões e tabela de factos) deve ser concebido de modo a poder ser executado de forma incremental, isto é, em cada execução só serem carregados os dados novos e atualizados os que já existem, caso tenham sofrido alterações.
- Constata-se que há diversas análises de dados aos totais mensais encomendados por cliente (e.g.: quantidade total; valor total). Tendo em conta esta realidade e o elevado volume de dados existente, pretende-se que o *data mart* suporte a realização dessas consultas da forma mais eficiente possível.
- As análises de dados às encomendas são apenas realizadas na unidade monetária local em que ocorreram (i.e., análises envolvendo uma só moeda) ou na unidade monetária de uniformização (i.e., análises envolvendo várias moedas). Sendo uma empresa nacional, a unidade monetária de uniformização é o Euro (Eur).
- O *Integration Services Project* deve ser elaborado de modo a que não existam caminhos (*paths*) absolutos nos diversos componentes. Todos estes caminhos têm de ser configuráveis mediante a sua especificação num ficheiro de parametrizações, assim como: nome do servidor de base de dados do sistema operacional; nome da base de dados do sistema operacional; nome do servidor de base de dados do *data mart* e da *staging area* (mesmo servidor para ambas); nome da base de dados do *data mart*; e, nome da base de dados da *staging area*.
- Deve ser criado um repositório no *GitHub* onde conste toda a documentação elaborada durante o desenvolvimento do projeto, bem como o *Integration Services Project* cujo desenvolvimento deve ser realizado de modo colaborativo entre ambos os elementos do grupo. A avaliação do trabalho terá em conta o contributo individual de cada elemento, com base nos *commits* efetuados no repositório e no seu conteúdo. O repositório será designado **ARMDD_25-26_XXXXXXX_YYYYYYY**, em que **XXXXXXX** e **YYYYYYY** representam os **números dos alunos** que constituem o grupo. No repositório deverá ser concedido permissões de acesso ao docente da aula PL a que pertencem os alunos do grupo.

- Proceder à elaboração de 20 análises multidimensionais de dados sobre o armazém de dados criado utilizando a ferramenta *PowerBI*. Das 20 análises de dados, 10 são realizadas “à escolha”, mas devem possuir graus de dificuldade diferentes e têm de incidir sobre as hierarquias que existam nos dados. As restantes 10 análises de dados encontram-se apresentadas de seguida, representando análises típicas que a gestão da empresa pretende efetuar às vendas a clientes. Note-se que estas 10 análises são meramente indicativas, pelo que o *data mart* não pode ser criado unicamente para lhes dar resposta.
 - Valores totais das encomendas efetuadas no primeiro trimestre de 2022, detalhados pelo sexo do cliente e pela categoria do produto.
 - Valores totais dos custos de expedição (frete) despendidos no transporte dos produtos durante o mês de fevereiro de 2022, detalhados pelo país de expedição e por categoria de produto.
 - Valores totais e respetivas quantidades referentes aos produtos encomendados no primeiro semestre de 2023, detalhados por site e por zona geográfica do cliente.
 - Valores das encomendas efetuadas sem e com custos de expedição durante o ano de 2023, detalhados pelos países para onde foram enviados que pertencem unicamente à zona Euro.
 - Valores totais e respetivas quantidades encomendadas efetuadas no último dia de cada mês do ano de 2022, detalhados por categoria do produto, com possibilidade de análise detalhada (i.e., *drill down*) ao nível individual do produto.
 - Valores totais dos custos de expedição referentes às encomendas realizadas na 6ª semana do ano de 2023, detalhados por caixa de expedição e por país de envio, com possibilidade de análise detalhada (i.e., *drill down*) ao nível do local de expedição.
 - Valores totais das encomendas e respetivas quantidades, efetuadas no 2º quadrimestre de 2023, detalhados pela zona geográfica do cliente e por produto, com possibilidade de análise agregada (i.e., *roll up*) ao nível da categoria do produto.
 - Valores totais das encomendas (em libras) efetuadas durante a primavera e verão de 2022, detalhados por país e sexo do cliente, apenas para os clientes cuja moeda seja libras (GBP).
 - Valores totais dos custos de expedição por cliente, com possibilidade de análise agregada (i.e., *roll up*) ao nível do país do cliente, e por mês do ano de 2023, com possibilidade de análise agregada (i.e., *roll up*) ao nível do trimestre, semestre ou

ano, unicamente para os produtos que pertençam às categorias “*Clothing*”, “*Shoes*” e “*Acessories*”.

- Valores totais e respetivas quantidades encomendadas ao fim-de-semana, nos anos de 2022 e 2023, dos produtos cujo tamanho máximo disponível seja 52, detalhados pelo país do site onde foi realizada a encomenda, com possibilidade de análise detalhada (i.e., *drill down*) ao nível do próprio site, e por tipo de serviço UPS, com possibilidade de análise detalhada (i.e., *drill down*) ao nível do próprio site.

A realização do trabalho é feita em **grupos de dois alunos** e envolve duas **partes complementares**.

Na **1ª parte** pretende-se que seja elaborado: arquitetura do armazém de dados para a situação descrita; modelo dimensional subjacente (com a apresentação dos atributos e respetivos tipos de dados para cada dimensão e tabela de factos); estruturas de dados (i.e., tabelas; ficheiros) a criar na *staging area*; mapeamento de dados entre os sistemas fonte e a *staging area* e entre a *staging area* e o armazém de dados (para os atributos das dimensões deve ser apresentada a estratégia de *Slowly Changing Dimension* (SCD); e, eventuais operações de transformação e limpeza de dados a realizar nos diversos atributos). Estes artefactos devem resultar na elaboração de um relatório.

Na **2ª parte** do trabalho pretende-se a implementação do armazém de dados, com a correspondente implementação dos processos de extração, transformação, limpeza, integração e carregamento dos dados. Esta parte deve ser documentada através da realização de um relatório final no qual constem todos os elementos relevantes para a avaliação final do trabalho, como: arquitetura do armazém de dados (final); modelo dimensional (final); estruturas de dados criadas na *staging area* (final); mapeamento de dados entre os sistemas fonte e a *staging area* e entre a *staging area* e o armazém de dados (o que inclui que para os atributos das dimensões seja apresentada a estratégia de *Slowly Changing Dimension* (SCD) (final); processos de extração, transformação, limpeza, integração e carregamento de dados efetuados; *scripts* SQL criados; análises dimensionais efetuadas mediante a apresentação das respetivas consultas; justificação das opções tomadas; melhoramentos possíveis; etc.

Prazo e Forma de Entrega da 1ª parte do Trabalho:

- O **relatório** tem de ser **submetido no Moodle** até às **23h59** do dia **23 de novembro de 2025**.

- O trabalho deve ser submetido sob a forma de um **único ficheiro PDF**, com o seguinte nome: **XXXXXXXX_YYYYYYY.pdf**, em que XXXXXXXX e YYYYYYY representam os **números dos alunos** que constituem o grupo.

Prazo e Forma de Entrega da 2ª parte do Trabalho:

- **O Trabalho** (relatório final + *integration services project*) tem de ser **submetido no Moodle** até às **23h59** do dia **4 de janeiro de 2026**.
- O trabalho deve ser submetido sob a forma de um **único ficheiro ZIP**, com o seguinte nome: **XXXXXXXX_YYYYYYY.zip**, em que XXXXXXXX e YYYYYYY representam os **números dos alunos** que constituem o grupo.
- A discussão do trabalho será efetuada com **ambos os elementos do grupo obrigatoriamente presentes**, em data e hora a combinar oportunamente.

O **incumprimento do prazo de entrega** implica uma **penalização na nota**, dessa parte do Trabalho, **de 20% por cada dia de atraso**.