

Departamento de Engenharia Informática

Mestrado em Engenharia Informática

Engenharia de Dados

Laboratório de Grandes Dados**Exame Época Normal**

20 de janeiro 2025

N.º _____ **Nome:** _____

Em cada pergunta só há uma resposta certa, se marcar mais do que uma será considerado que não respondeu à questão.

- Responda na própria folha, marcando com um X ou ■ (pode usar o lápis)
- Se pretender anular uma resposta escreva "anulada" à esquerda da mesma (por exemplo, anulada ■-xpto)

- [1 val.] Qual das seguintes afirmações melhor descreve o significado de "Valor" no âmbito dos 5Vs do *Big Data*?
 - A diversidade de tipos e fontes de dados, incluindo dados estruturados, semiestruturados e não estruturados.
 - A capacidade de armazenar grandes volumes de dados.
 - A rapidez com que os dados são gerados, recolhidos e processados.
 - A importância e a utilidade dos dados extraídos, que podem ser convertidos em informação para suportar o processo de tomada de decisões.
- [1 val.] Qual a desvantagem dos *Data Warehouses* relativamente aos *Data Lake*:
 - Armazenam apenas dados que foram tratados e transformados.
 - Suportam o armazenamento de dados em qualquer tipo de estrutura, incluindo dados brutos e não processados.
 - São adequados apenas para armazenar grandes volumes de dados não estruturados.
 - Armazenam somente dados brutos e não processados.
- [1 val.] Os *Data Lake*:
 - são geralmente implementados usando apenas sistemas de bases de dados tradicionais devido à sua eficiência em armazenar grandes volumes de dados.
 - permitem o armazenamento de dados em formatos estruturados, semiestruturados e não estruturados, oferecendo flexibilidade na análise e no processamento de diferentes tipos de dados.
 - são adequados apenas para armazenar grandes volumes de dados não estruturados.
 - não adequados para soluções de *Big Data* por não suportarem alguns tipos de dados.
- [1 val.] Um *Data Mesh*:
 - É um repositório centralizado que ingere e armazena grandes volumes de dados.
 - É um repositório descentralizado para armazenamento de grandes volumes de dados.
 - É indicado para pequenos *datasets*.
 - Utiliza apenas a última camada de um modelo pré-treinado.
- [1 val.] A camada de processamento numa arquitetura de *Big Data*:
 - Permite armazenar grandes volumes de dados brutos de diversas fontes.
 - É responsável pela recolha e ingestão dos dados em tempo real ou em *batch*, organizando-os antes do armazenamento.
 - Transforma e analisa dados, aplicando algoritmos para gerar resultados para outras camadas.
 - Fornece a interface de visualização de dados, permitindo que os utilizadores finais interpretem os resultados das análises.

6. [1 val.] O *Apache Spark* oferece várias bibliotecas integradas que ampliam as suas capacidades para além do processamento de dados em *batch*. Qual é a biblioteca projetada especificamente para simplificar o desenvolvimento de algoritmos de *Machine Learning* em larga escala?
- Spark SQL
 - MLlib
 - Spark Streaming
 - GraphX
7. [1 val.] Que tipo de rede Blockchain permite que várias organizações colaborem e partilhem dados de forma segura?
- Blockchain Pública
 - Blockchain Privada
 - Blockchain Híbrida
 - Blockchain de Consórcio
8. [1 val.] Uma rede de objetos físicos (sensores, e dispositivos inteligentes), com o objetivo de interligar e trocar dados com outros dispositivos e sistemas pela Internet, sem intervenção humana:
- Rede Neuronal
 - Cloud Computing
 - Internet of Things
 - Blockchain
9. [1 val.] Fornece ferramentas, como parte dos serviços da Cloud Computing, com estruturas para tarefas de inteligência artificial, como treino e ajuste de modelos, análise preditiva, processamento de linguagem natural, pré-processamento de dados, previsão e visualização:
- MLaaS
 - Apache Spark*
 - MLlib
 - Kafka
- 10.[1 val.] O *MapReduce* é essencial no ecossistema *Hadoop* para processamento paralelo e distribuído de grandes volumes de dados. Qual é a principal função do componente "Reduce" no modelo MapReduce?
- Dividir os dados de entrada em partes menores (amostras) que podem ser processadas em paralelo pelos *mappers*.
 - Processar cada parte dos dados (amostra) de entrada de forma independente e gerar um conjunto intermediário de dados.
 - Agregar os resultados produzidos pelos *mappers*, realizando operações de síntese como somatórios, contagem ou ordenação.
 - Distribuir os dados de entrada pelos diferentes nós do cluster para otimizar a eficiência do processamento.
- 11.[1 val.] O *YARN (Yet Another Resource Negotiator)* é um sistema de ficheiros distribuídos que integra a framework:
- Spark
 - Hadoop
 - MLlib
 - Apache
12. [1 val.] Qual é a função das ferramentas de Inteligência Artificial em Big Data?
- Reduzir a quantidade de dados a serem analisados.
 - Analisar e interpretar grandes volumes de dados.
 - Analisar dados não-estruturados de *datasets* públicos.
 - Proteger dados privados de organizações.

13. [2,5 val.] “Considerando os atuais desenvolvimentos tecnológicos, a capacidade de armazenamento e geração de dados digitais cresceu de forma exponencial, alcançado níveis que superam significativamente as expectativas da sociedade de alguns anos atrás. Esta área científica caracterizada pela sua grandeza, complexidade e procura por novas técnicas e tecnologias para o seu processamento é conhecida como *Big Data*”. Comente a frase. Identifique e relacione as principais vantagens e desafios associados ao paradigma Big Data.
- 14.[2,5 val.] A *Cloud Computing* tornou-se parte integrante das infraestruturas da tecnologia moderna, tendo revolucionando a forma como as organizações gerem e fornecem serviços através na Internet. Caracterize os principais modelos de serviços na *Cloud* (IaaS, PaaS, SaaS, XaaS).

- 15.[3 val.] As GPUs, enquanto processadores especializados para processamento gráfico, inicialmente desenvolvida para renderizar imagens em jogos e aplicações gráficas têm sido cada vez mais usados no contexto do treino de modelos complexos em Big Data. Identifique e caracterize as principais razões e contribuições do uso de GPUs no âmbito do desenvolvimento de modelos *Deep Learning*.